Extracción Extracción Leyes del texto

Extracción de información

Tecnologías de búsqueda en la web

Marcelo Mendoza



Leyes del texto

 MM
 INF-335
 1 / 52
 MM
 INF-335
 2 / 52

 Extracción
 Leyes del texto
 Extracción
 Leyes del texto

George Kingsley Zipf

El principio del mínimo esfuerzo (1949, Zipf)





George Kingsley Zipf (1949), Human behavior and the principle of least effort, Addison-Wesley Press

MM INF-335 3 / 52 MM INF-335 4 / 52

Ley de Zipf

Zipf para Reuters²

16000

14000 12000

10000

8000

6000

4000 2000

Ley de Zipf

Reuters¹



¹Agencia de noticias

6 / 52

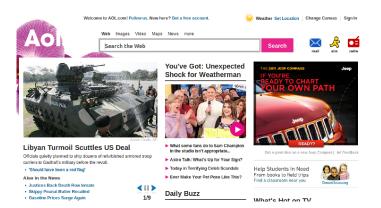
Extracción Leyes del texto

²Dataset de noticias, disponible on-line

Extracción Leyes del texto

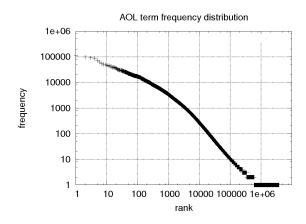
Ley de Zipf

AOL^3



Ley de Zipf

Zipf para AOL query log⁴



⁴Dataset de consultas formuladas a AOL, disponible on-line

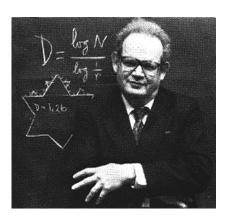
INF-335 8 / 52 Extracción Leyes del texto Extracción Leyes del texto

Limitaciones del ajuste Zipf

| Word | Freq. | Rank | $f \cdot r$ | Word | Freq. | Rank | $f \cdot r$ |
|-------|-------|--------------|-------------|------------|--------------|--------------|-------------|
| | (f) | (<i>r</i>) | | | (<i>f</i>) | (<i>r</i>) | |
| the | 3332 | 1 | 3332 | turned | 51 | 200 | 10200 |
| and | 2972 | 2 | 5944 | you'll | 30 | 300 | 9000 |
| a | 1775 | 3 | 5235 | name | 21 | 400 | 8400 |
| he | 877 | 10 | 8770 | comes | 16 | 500 | 8000 |
| but | 410 | 20 | 8400 | group | 13 | 600 | 7800 |
| be | 294 | 30 | 8820 | lead | 11 | 700 | 7700 |
| there | 222 | 40 | 8880 | friends | 10 | 800 | 8000 |
| one | 172 | 50 | 8600 | begin | 9 | 900 | 8100 |
| about | 158 | 60 | 9480 | family | 8 | 1000 | 8000 |
| more | 138 | 70 | 9660 | brushed | 4 | 2000 | 8000 |
| never | 124 | 80 | 9920 | sins | 2 | 3000 | 6000 |
| Oh | 116 | 90 | 10440 | Could | 2 | 4000 | 8000 |
| two | 104 | 100 | 10400 | Applausive | 1 | 8000 | 8000 |

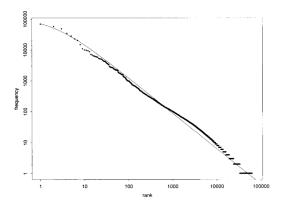
Producto $f \cdot r$ en el libro *Tom Sawyer*, versión en inglés.

Benoit Mandelbrot (1954)



Mandelbrot, B. (1954) Structure formelle des textes et communcation. Word, 10:1-27.





Ajuste Mandelbrot en el corpus Brown ⁵.

⁵The Brown Corpus was the first million-word electronic corpus of English, created in 1961 at Brown University. This corpus contains text from 500 sources, and the sources have been categorized by genre, such as news, editorial, and so on

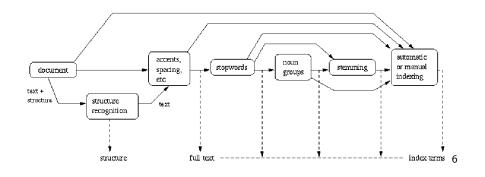


MM INF-335 11 / 52 MM INF-335 12 / 52

Extracción Leyes del texto Extracción Preprocesamiento del texto Ley de Heaps 10000 8000 Preprocesamiento del texto 6000 4000 2000 200000 400000 6000000 8000000 1e+06 texto Extracción Preprocesamiento del texto Extracción Preprocesamiento del texto

Preprocesamiento de texto

Problemas recurrentes con idiomas





ノーベル平和賞を受賞したワンガリ・マータイさんが名誉会長を務め クーヘル平和員を受責したソフカリ・マータイさんか名音芸技を務めるMOTTAINAIキャンペーンの一張として、毎日新聞社とマガジンハウスは「私の、もったいない」を募集します。皆様が日ごろ「もったいない」と感じて実践していることや、それにまつわるエピソードを800字以内の文章にまとめ、簡単な写真、イラスト、図などを添えて10月20日までにお送りください。大賞受賞者には、50万円相当の旅行券とエコ製品2点の副賞が贈られます。

Japonés

استقلت الجز انر في سنة 1962 بعد 132 عاما من الاحتلال الفرنسي. 'Algeria achieved its independence in 1962 after 132 years of French occupation.'

Árabe

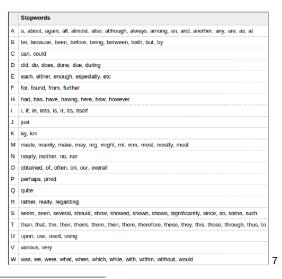
Árabe

⁶Ref.: R. Baeza & B. Ribeiro, Modern Information Retrieval, 1999.

Extracción Preprocesamiento del texto Extracción Preprocesamiento del texto

Stopwords (español)

Stopwords (inglés)



⁷http://www.pubmed.gov

vuestras, vuestro, vuestros, y, yo.

a, acá, ahí, ajena, ajenas, ajeno, ajenos, al, algo, alguna, algunas, alguno, algunos, algún, allá,

allí, aquel, aquella, aquellas, aquello, aquellos, aquí, cada, cierta, ciertas, cierto, ciertos, como, cómo, con, conmigo, consigo, contigo, cualquier, cualquiera, cualquieras, cuan, cuanta, cuantas,

cuánta, cuántas, cuanto, cuantos, cuán, cuánto, cuántos, de, dejar, del, demasiada, demasiadas,

muchísimo, muchísimos, mucho, muchos, muy, nada, ni, ninguna, ningunas, ninguno, ningunos,

no, nos, nosotras, nosotros, nuestra, nuestra, nuestro, nuestros, nunca, o, os, otra, otras, otro,

quienesquiera, quienquiera, quién, si, siempre, sí, sín, Sr, Sra, Sres, Sta, suya, suyas, suyo, suyos,

tal, tales, tan, tanta, tantas, tanto, tantos, te, tener, ti, toda, todas, todo, todos, tomar, tuya, tuyo, tú, un, una, unas, unos, usted, ustedes, varias, varios, vosotras, vosotros, vuestra,

demasiado, demasiados, demás, el, ella, ellas, ellos, él, esa, esas, ese, esos, esta, estar, estas,

este, estos, hacer, hasta, jamás, junto, juntos, la, las, lo, los, mas, más, me, menos, mía,

mientras, mío, misma, mismo, mismo, mucha, muchas, muchísima, muchísimas,

otros, para, parecer, poca, pocas, poco, pocos, por, porque, que, qué, quien, quienes,

Extracción Preprocesamiento del texto

Extracción Preprocesamiento del texto

Tres algoritmos de stemming: comparación

Texto de ejemplo: Such an analysis can reveal features that are not easily visible from the variations in the individual genes and can lead to a picture of expression that is more biologically transparent and accessible to interpretation

Porter: such an analysi can reveal featur that ar not easili visibl from the variat in the individu gene and can lead to a pictur of express that is more biolog transpar and access to interpret

Lovins: such an analys can reve featur that ar not eas vis from th vari in th individu gen and can lead to a pictur of expres that is mor biolog transpar and acces to interpres

Paice: such an analys can rev feat that are not easy vis from the vary in the individ gen and can lead to a pict of express that is mor biolog transp and access to interpret

Martin Porter (1980)



http://tartarus.org/~martin/

Extracción Corpus

Peter Roget's Thesaurus

Corpus



22 / 52

Extracción Corpus

Extracción Corpus

Roget's 2000

Roget 2000 was proposed as a tool for semantic research by Prof Dr. Rudolf Wille, founder of Formal Concept Analysis (FCA). This project follows conceptually from more 30 years of research by Dr Walter A. Sedelow Jr. and Dr Sally Yeates Sedelow. It was implemented jointly by Dr Uta Priss, a student of Select Category

Webster on-line

Webster's Online Dictionary



Coming in 2009: timelines, translations, sound effects, and a big surprise!

Ver más en http://www.websters-online.dictionary.org

Ver más en http://www.roget.org

xtracción Corpus Extracción Corpus

WordNeT WordNeT

WordNet Search - 3.0 - <u>WordNet home page - Glossary - Help</u>
Word to search for: car Search WordNet
Display Options: (Select option to change) V Change
Key: "S:" = Show Synset (semantic) relations, "W:" = Show Word (lexical) relations

Noun

- S: (n) car, auto, automobile, machine, motorcar (a motor vehicle with four wheels; usually propelled by an internal combustion engine) "he needs a car to get to work"
- S: (n) car, railcar, railway car, railroad car (a wheeled vehicle adapted to the rails of railroad) "three cars had jumped the rails"
- S: (n) car, gondola (the compartment that is suspended from an airship and that carries personnel and the cargo and the power plant)
- S: (n) car, elevator car (where passengers ride up and down) "the car was on the top floor"
- S: (n) cable car, car (a conveyance for passengers or freight on a cable railway) "they took a cable car to the top of the mountain"

Ver más en http://www.wordnet.princeton.edu

Extracción Corpus Extracción Corpus

Hipónimos en WordNet (car)

wn car -hypon

Sense 1:

car, auto, automobile, machine, motorcar

- ambulance
- beach wagon, station wagon, wagon, beach waggon
- bus, jalopy, heap
- cab, hack, taxi, taxicab
- compact, compact car
- convertible
- coupe
- cruiser, police cruiser, patrol car, police car
- electric, electric automobile, electric car
- gas guzzler
- hardtop

Hipérnimos en WordNet (car)

WN(1WN)

OPTIONS

٠l

WordNet™ User Commands

wn [<u>searchstr</u>] [-h] [-g] [-a] [-l] [-o] [-s] [-n#] [

wm() provides a command line interface to the WordNet database, allowing synsets and relations to be displayed as formatted text. For each

word, different searches are provided, based on syntactic category and pointer types. Although only base forms of words are usually stored in

WordNet, users may search for inflected forms. A morphological process is applied to the search string to generate a form that is present in WordNet with Searchery $-|\mathbf{h}| = \mathbf{g} - \mathbf{g} - \mathbf{g} - \mathbf{h} = \mathbf{g}$

The command line interface is often useful when writing scripts to extract information from the WordNet database. Post-processing of the output with various scripting tools can reformat the results as

Print help text before search results.

Display lexicographer file information.

Display synset offset of each synsetement results.

Display each word's sense numbers in synsets with synsets.

Display textual glosses associated with synsets rious scripting

Display the WordNet copyright notice, version number,

wn - command line interface to WordNet lexical database

search option WordNer User Commands

wn car -hypen

Sense 1

car, auto, automobile, machine, motorcar

- motor vehicle, automotive vehicle
- self-propelled vehicle
- wheeled vehicle
- vehicle
- conveyance, transport
- instrumentality, instrumentation
- artifact, artefact
- object, physical object
- entity
- whole, whole thing, unit
- object, physical object
- entity

...

MM INF-335 27 / 52 MM INF-335 28 / 52

Merónimos en WordNet (car)

wn car -meron

Sense 1

car, auto, automobile, machine, motorcar

HAS PART: accelerator, accelerator pedal, gas pedal

HAS PART: air bag

HAS PART: auto accessory

HAS PART: automobile engine

HAS PART: automobile horn, car horn, motor horn, horn, hooter

HAS PART: buffer, fender

HAS PART: bumper

HAS PART: car door

HAS PART: car mirror

HAS PART: car seat

HAS PART: car window

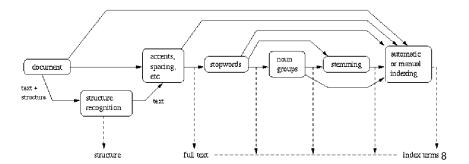
Métodos estándar en IR

Extracción Métodos estándar en IF

Extracción Métodos estándar en IF

Preprocesamiento de texto clásico en IR

Token v/s término



- ► Token String delimitado que aparece en el texto.
- ► Término token con significado según un corpus (por ejemplo diccionario)

⁸Ref.: R. Baeza & B. Ribeiro, Modern Information Retrieval, 1999.

Tokenización

Tokenizar es difícil – (sobretodo en Inglés)

► Input:

amigos, Romans, habitantes. habia una vez ... Cesar ...

Output:

amigo romano habitante cesar . . .

- ► Cada token es candidato a término.
- ► Cuáles elegimos? Depende del corpus.

Ejemplo 1: Mr. O'Neill thinks that the boys' stories about Chile's capital aren't amusing.

Ejemplo 2: Miss lilly higgins sings shimmy in mississippi's spring.



- **▶** 3/12/91
- **▶** 12/3/91
- ► Marzo 12, 2008
- ► B-52
- ▶ 100.2.86.144
- **(**32**)** 234-2333
- **800.234.2333**
- Los primeros IR no indexaban números, pero generalmente son útiles.

莎拉波娃现在居住在美国东南部的佛罗里达。今年4月 9日,莎拉波娃在美国第一大城市纽约度过了18岁生 日。生日派对上,莎拉波娃露出了甜美的微笑。

MM INF-335 35 / 52 MM INF-335 36 / 52

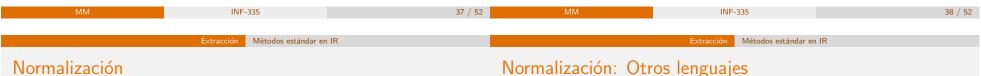
Tokenización ambigua en Chino

Tokenización ambigua en otros idiomas



Si son usados de forma separada hay dos significados, si se indexan juntos hay un significado.

- ► Composición en Alemán
- ▶ Computerlinguistik → Computer + Linguistik
- ► Lebensversicherungsgesellschaftsangestellter
- ightharpoonup ightharpoonup leben + versicherung + gesellschaft + angestellter
- tusaatsiarunnanngittualuujunga (no escucho muy bien!)
- ► Sueco, Finés, Griego, entre otros.



- Es necesario "normalizar" términos en texto indexado así como los términos de las consultas.
- ► Ejemplo: Queremos 'matching' entre U.S.A. y USA
- ▶ Implícitamente lo que estamos haciendo es definir clases de equivalanecia de términos.
- Alternativa: hacer expansión asimétrica.
 - window → window, windows
 - windows → Windows, windows
 - Windows
- Mas poderosas pero menos eficientes
- ▶ Por qué no colocar window, Window, windows, y Windows en la misma clase de equivalencias?

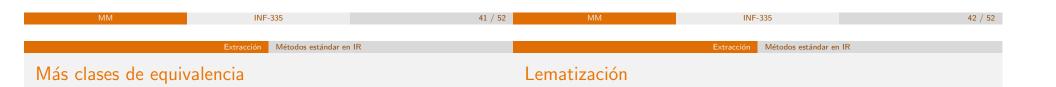
- - Acentos: résumé vs. resume.
 - Cremillas: Universität vs. Universitaet
 - Más importante aún: Cómo los usuarios formulan estas consultas frecuentemente?
- ▶ En lenguajes donde usualmente se usan acentos, las consultas se formulan sin ellos.
- ▶ PETER WILL NICHT MIT. → MIT = mit
- ▶ El obtuvo su PhD en el MIT. \rightarrow MIT \neq mit

Mayúsculas

Stop words

- Reducir todo a minúsculas
- Excepciones posibles: marcas
- ► MIT vs. mit
- ► Fed vs. fed

- stop words = palabras usadas comúnmente que tienen un bajo valor descriptivo
- ► Ejemplos: e, y, o, en, de, pero, para, por, el, la, los las, desde, hasta, ...
- ▶ Los primeros sistemas IR eliminaban las stop words del vocabulario.
- ▶ Para consultas de frases son necesarias las stop words, e.g. "Rey de España"
- ► Actualmente varios motores de búsqueda indexan stop words.



- ► Sonido: (equivalencia fonética, Tchebyshev = Chebysheff)
- ► Thesauri: (equivalencia semántica, auto = carro)

- Reducir formas infleccionales a su raíz
- ightharpoonup Ejemplo: am, are, is o be
- ightharpoonup Ejemplo: autos, auto, automoviles ightarrow auto
- ► Ejemplo: Los autos de los jóvenes son de colores → auto joven es color
- Lematización implica realizar una reducción hacia la raíz (lema). $(destruccion \rightarrow destruir)$

MM INF-335 43 / 52 MM INF-335 44 / 52

Stemming

Algoritmo de Porter

- ▶ Definición de stemming: Proceso heurístico que corta la derivación de las palabras para encontrar la raíz (es un tipo de lematización).
- ► Es dependiente del lenguaje
- ► Infleccional y derivacional
- ► Ejemplo de derivacional: *automata, automatico, automatizado* se reduce a *automata*

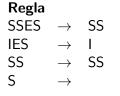
- ▶ Algoritmo de stemming más comúnmente usado en Inglés
- ► Los resultados sugieren de que es al menos tan bueno como otros algoritmos de stemming
- ► Convenciones + 5 fases de reducción
- Las fases son aplicadas secuencialmente
- Cada fase consiste de un conjunto de reglas.
 - Regla de ejemplo: Eliminar la derivación *ement* si el largo del prefijo es mayor que 1
 - \blacksquare replacement \rightarrow replac
 - lacksquare cement ightarrow cement
- ► Convención de ejemplo: Si hay varias reglas que se pueden aplicar en un mismo caso, use aquella que se aplica a un sufijo más largo.

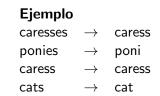
 MM
 INF-335
 45 / 52
 MM
 INF-335
 46 / 52

 Extracción
 Métodos estándar en IR
 Extracción
 Métodos estándar en IR

Algoritmo de Porter: Unas pocas reglas

Tres algoritmos de stemming: comparación





Texto de ejemplo: Such an analysis can reveal features that are not easily visible from the variations in the individual genes and can lead to a picture of expression that is more biologically transparent and accessible to interpretation

Porter: such an analysi can reveal featur that ar not easili visibl from the variat in the individu gene and can lead to a pictur of express that is more biolog transpar and access to interpret

Lovins: such an analys can reve featur that ar not eas vis from th vari in th individu gen and can lead to a pictur of expres that is mor biolog transpar and acces to interpres

Paice: such an analys can rev feat that are not easy vis from the vary in the individ gen and can lead to a pict of express that is mor biolog transp and access to interpret

MM INF-335 47 / 52 MM INF-335 48 / 52

Mejora el stemming la efectividad de IR?

- ► En general, stemming mejora la efectividad en algunas consultas, y la desmejora en otras.
- Mientras más regular es la gramática, mejor.
- ► En castellano es difícil (gramática muy irregular).

Programación en NLTK

